


C17：多付小规模 CPU 位复制，少做更昂贵的 NPU 布局恢复



A/C: S13, 各方案 40 次, 合成 checkpoint 输入; B: 每帧 60 次, hidden 经 CPU FP32 重建, C17 输出未反馈进 Euler。
Q/RoPE + Cross Attention + 输出投影/残差, 不含 MLP。准备/提交/同步/最终读回已计; 公共原始 Prefix 打包等额排除。